

Teste Qui-quadrado (independência)

Como vimos antes, o teste de hipóteses Qui-quadrado pode ser utilizado como:

- (i) um teste de aderência, para verificar o grau de correspondência entre os valores observados e esperados de uma distribuição teórica, (ii) uma extensão do teste binomial, para os casos onde as observações da população estão divididas em mais de duas categorias discretas ou (iii) como um teste de independência, para verificar se existe independência entre duas ou mais amostras. Especificamente, o teste de hipóteses Qui-quadrado como teste de independência é utilizado quando se possui dados representados em forma de frequência como intuito de avaliar a significância estatística entre dois grupos (amostras) independentes, possuindo as mesmas características e procedimentos do teste para uma amostra. Assim como os demais testes para duas amostras, o teste Qui-quadrado também possui um procedimento inicial, que é alocar as frequências observadas em uma tabela de frequências $r \times k$, onde r são as categorias (linhas) e k são as amostras (colunas). A partir disto, os valores esperados são calculados, assumindo N o número total de observações, que é utilizado para calcular os valores totais R por linhas e C por colunas. Esta tabela é conhecida como tabela de contingência e está representada na tabela 1.

Tabela 1 – Tabela de contingência

Classe	Amostra 1	Amostra 2	
1	o_{11}	o_{12}	$R_1 = o_{11} + o_{12}$
2	o_{21}	o_{22}	$R_2 = o_{21} + o_{22}$
3	o_{31}	o_{32}	$R_3 = o_{31} + o_{32}$
r	o_{r1}	o_{r2}	$R_r = o_{r1} + o_{r2}$
Total	$C_1 = o_{11} + o_{21} + \dots + o_{r1}$	$C_2 = o_{12} + o_{22} + \dots + o_{r2}$	$N = C_1 + C_2$

Assim, o teste de hipóteses Qui-quadrado de independência é um teste que determina a significância das diferenças entre as proporções de dois grupos (amostras) independentes. Desta forma, testamos a hipótese de que as amostras provêm de uma mesma população (não são independentes), sendo a hipótese nula definida por $H_0: \pi_{a_1} = \pi_{a_2}, \pi_{b_1} = \pi_{b_2}, \dots, \pi_{n_1} = \pi_{n_2}$. Considerando o quadrado da diferença entre os valores observados (o) e esperados (e) para cada categoria r e amostra k , temos que a estatística teste do teste Qui-quadrado será

$$\chi^2_t = \sum_{i=1}^r \sum_{j=1}^k \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

a qual será comparada com o valor crítico dado pela tabela Qui-quadrado. Para isto, é necessário a definição do grau de liberdade, neste caso como $(r - 1)(k - 1)$, e os valores esperados obtidos por meio da equação $e_{ij} = \frac{R_i C_j}{N}$, onde R_i é a soma da linha i , C_j é a soma da coluna j , e N é o total de observações das amostras em conjunto. A tabela 2 apresenta a tabela de contingência com os valores observados e esperados.

Tabela 2 – Tabela de contingência

Classe	Amostra 1	Amostra 2	
1	$o_{11} - e_{11}$	$o_{12} - e_{12}$	$R_1 = o_{11} + o_{12}$
2	$o_{21} - e_{21}$	$o_{22} - e_{22}$	$R_2 = o_{21} + o_{22}$
3	$o_{31} - e_{31}$	$o_{32} - e_{32}$	$R_3 = o_{31} + o_{32}$
r	$o_{r1} - e_{r1}$	$o_{r2} - e_{r2}$	$R_r = o_{r1} + o_{r2}$
Total	$C_1 = o_{11} + o_{21} + \dots + o_{r1}$	$C_2 = o_{12} + o_{22} + \dots + o_{r2}$	$N = C_1 + C_2$

Valores da estatística teste (χ^2_t) à direita do valor crítico (χ^2_c) constituem a região de rejeição. Para tabelas 2x2, se $N > 20$ e todas as frequências esperadas forem superiores a cinco, este teste pode ser utilizado, caso contrário, deve-se utilizar o teste exato de Fisher (não abordado neste curso).